Projeto 2 - CB

Projeto Final: Mini-pesquisa

Educacional – Insper Data

Ciclo Básico – 2026.2

Entregas: apresentação inicial até **21/10** e apresentação final em **12/11 ou 19/11**

Apresentação

Neste projeto final do Ciclo Básico, cada dupla vai conduzir uma **mini-pesquisa**, o mais próxima possível do que é feito nos projetos regulares do Insper Data. Diferente do Projeto 1, em que a base e a pergunta-guia foram definidas pela coordenação, agora **o tema é livre**: cabe à dupla escolher o assunto, formular a própria pergunta, encontrar e preparar os dados e investigá-la com tudo o que foi visto ao longo do ciclo, da limpeza e da análise exploratória à regressão linear e ao machine learning.

A pesquisa **não precisa ser preditiva**. O papel da regressão e do machine learning neste projeto é dar sustentação à análise: mostrar que as relações observadas na exploração dos dados continuam de pé quando outras variáveis são levadas em conta e quando o modelo é avaliado em dados que ele não viu. Não esperamos o modelo mais sofisticado, e sim uma conclusão bem argumentada, acompanhada de uma discussão honesta sobre o que os dados permitem e o que não permitem afirmar.

O projeto tem duas entregas. Até **21/10**, cada dupla faz uma apresentação curta de proposta, nos moldes da primeira apresentação dos projetos regulares, mostrando o tema, a pergunta e o plano de trabalho. Em **12/11 ou 19/11** (data a ser confirmada pela coordenação) acontece a apresentação final, com a pesquisa completa.

Não se esqueçam de criar o repositório no GitHub logo no início do projeto, com a dupla adicionada como colaboradora. Ele deve acompanhar todo o desenvolvimento, e não ser montado na véspera da entrega. Se precisarem de ajuda em qualquer etapa, mandem mensagem!

Escolha do tema e da pergunta

O ponto de partida deve ser um problema que importa, e não a primeira base de dados que aparecer. Uma notícia, um número que chama atenção ou uma questão real de alguma área de interesse da dupla (segurança pública, educação, saúde, economia, esportes, cultura, meio ambiente, tecnologia, entre outras) costumam render boas perguntas. Escolhido o tema, verifiquem cedo se existem dados abertos que permitam investigá-lo. Portais como a Base dos Dados, o IBGE (SIDRA), o Ipeadata, o DATASUS, o INEP e o dados.gov.br são bons pontos de partida; bases do Kaggle também são aceitas, desde que a origem dos dados esteja clara.

Uma boa pergunta de pesquisa é específica, pode ser respondida com os dados disponíveis dentro do prazo e admite a possibilidade de estar errada. “Como está a educação nos municípios brasileiros?” é uma pergunta descritiva demais para um projeto como este; “o gasto público por aluno está associado ao desempenho dos municípios no Ideb, considerando renda e porte populacional?” já indica o que medir, o que comparar e o que poderia contrariar a ideia inicial. A pergunta pode ser explicativa (quais fatores se associam a um fenômeno), comparativa (se dois grupos diferem e se a diferença persiste quando outras variáveis são consideradas) ou preditiva (se é possível prever um resultado a partir de certas características). O importante é que a dupla deixe claro qual é o objetivo e escolha as ferramentas de acordo com ele.

Antes de rodar qualquer modelo, escrevam o que esperam encontrar e por quê. Essas expectativas funcionam como hipóteses: a análise pode confirmá-las, refutá-las ou mostrar que os dados não são suficientes para decidir, e qualquer um desses desfechos é um resultado válido quando bem justificado.

Apresentação inicial (até 21/10)

A primeira entrega é uma apresentação de **5 a 6 minutos**, no estilo da primeira apresentação dos projetos regulares. O objetivo é mostrar o que a dupla pretende fazer e como pretende chegar lá; ainda não se esperam resultados. Assim como no Projeto 1, pensem em storytelling: comecem pelo contexto e pela motivação do tema, mostrando por que o problema é relevante e para quem, de preferência com o apoio de fontes reais, e só então cheguem à pergunta de pesquisa.

Em seguida, apresentem a base (ou as bases) de dados que pretendem usar: de onde vêm, o que cada linha representa, qual é a variável de interesse, quais são as principais variáveis explicativas e que dificuldades já foram identificadas, como dados faltantes ou fontes com períodos e níveis de agregação diferentes. Contem também o que esperam encontrar.

Fechem com um **mini roadmap**: quais etapas faltam até a apresentação final (obtenção e limpeza dos dados, análise exploratória, modelagem e conclusões), como pretendem distribuí-las nas semanas que restam e que tipo de modelo imaginam usar, ainda que de forma preliminar. Vale apontar também os principais riscos do plano, como um dado que talvez não exista no nível de detalhe necessário. A coordenação vai usar essa apresentação para dar feedback e, se preciso, ajudar a ajustar o escopo antes que o trabalho mais pesado comece. O repositório no GitHub já deve existir nessa data, mesmo que ainda com pouco conteúdo.

Desenvolvimento da pesquisa

Entre as duas apresentações, a dupla executa o plano. O caminho é parecido com o do Projeto 1, com uma diferença importante: a análise exploratória deixa de ser o ponto final e passa a ser a base que justifica e orienta a modelagem.

Na **preparação dos dados**, documentem cada decisão tomada: como os dados foram obtidos e combinados, o que foi feito com valores ausentes, duplicados e outliers, e quantas observações e variáveis restaram ao final de cada etapa. O dado bruto não deve ser editado à mão; todas as transformações precisam estar no código, de modo que a análise possa ser reproduzida do início ao fim.

A **análise exploratória** deve olhar para a distribuição da variável de interesse, para a relação dela com cada variável explicativa e para a correlação entre as próprias variáveis explicativas, sempre com as hipóteses da dupla em mente, e deve terminar com uma decisão de modelagem justificada. Em um projeto regular do semestre passado, por exemplo, a exploração mostrou que a maior parte dos municípios tinha zero ocorrências do fenômeno estudado e que várias variáveis explicativas eram fortemente correlacionadas entre si; foi isso que levou o grupo a descartar uma regressão linear simples e a escolher outro modelo.

Na **modelagem**, o modelo funciona como um teste da história contada pela análise exploratória. Esperamos, no mínimo, uma regressão de referência com os coeficientes interpretados na linguagem do problema (o que significa, na prática, o aumento de uma unidade em cada variável) e comparados ao que a dupla esperava encontrar, acompanhada de uma checagem dos resíduos e da multicolinearidade. Mesmo que a pergunta não seja preditiva, separem os dados em treino e teste (ou usem validação cruzada) e comparem o desempenho do modelo com o de uma previsão ingênua, como prever sempre a média; um modelo que não supera essa referência não sustenta conclusão nenhuma. Por fim, usem ao menos um modelo de machine learning visto em aula e comparem o que ele indica com o que a regressão mostrou, verificando, por exemplo, se as variáveis mais importantes são as mesmas. Quando abordagens diferentes contam a mesma história, a conclusão ganha força; quando divergem, isso também é um resultado e merece ser discutido.

Alguns cuidados valem para todas as duplas. O conjunto de teste não deve ser usado para escolher

modelos ou ajustar parâmetros, e transformações como padronização ou preenchimento de valores ausentes devem ser ajustadas apenas com os dados de treino, para evitar vazamento de informação. Testar dezenas de combinações de variáveis e apresentar só a que "deu certo" compromete a credibilidade da análise. E um coeficiente estatisticamente significativo indica associação, não causalidade.

As **conclusões e limitações** devem ter o mesmo destaque que a resposta em si, como já foi pedido no Projeto 1. Discutam quais variáveis relevantes ficaram de fora do modelo, se os dados medem de fato o que se queria medir, se a base final é representativa e até onde os resultados podem ser generalizados. A linguagem da conclusão deve acompanhar a força da evidência: "está associado a" e "os dados sugerem", em vez de "causa" ou "prova".

Apresentação final (12/11 ou 19/11)

A apresentação final terá de **10 a 15 minutos**, seguidos de perguntas, com slides feitos a partir do template do Data. Ela deve contar a pesquisa completa como uma história: o contexto que leva à pergunta, os dados e as principais decisões de limpeza, os achados da análise exploratória, a modelagem e sua validação, e a conclusão acompanhada das limitações. Como referência, reservem cerca de 3 minutos para contexto e pergunta, 2 para os dados, 4 a 5 para análise exploratória e modelagem, e 3 a 4 para conclusão e limitações. Assim como na primeira apresentação, o foco é comunicar com clareza, e não mostrar o código. A aula de Studio e pré-apresentações, em 05/11, será o momento de ensaiar e receber feedback da coordenação antes da apresentação final.

Entrega

O repositório no GitHub é obrigatório e deve conter os notebooks com todo o código da análise, rodando do início ao fim, os gráficos gerados, a base de dados utilizada (se o tamanho do arquivo permitir) ou instruções claras de como obtê-la, e um arquivo com as dependências do projeto. O `README.md` deve funcionar como um pequeno relatório da pesquisa, explicando o problema, a pergunta, os dados, os métodos, os principais resultados e as limitações. Esperamos ver commits dos dois integrantes da dupla ao longo do projeto. Enviem o link do repositório à coordenação até uma hora antes da apresentação final.

Critérios de avaliação

Os critérios abaixo guiam a devolutiva da coordenação ao longo do projeto e na apresentação final.

Critério	O que observamos	Peso
Pergunta e planejamento	Storytelling, relevância do tema, pergunta clara com objetivo bem definido, expectativas explícitas e mini roadmap coerente na apresentação inicial	20%
Dados e análise exploratória	Fontes bem definidas, decisões de limpeza justificadas e documentadas, gráficos ligados às hipóteses e decisão de modelagem argumentada	30%
Modelagem, conclusão e limitações	Regressão de referência, comparação com baseline, modelo de ML, interpretação correta dos resultados.	40%
Comunicação e repositório	Clareza e tempo da apresentação, README, reprodutibilidade e commits dos dois integrantes	10%

Material de apoio

Os materiais das aulas do Ciclo Básico continuam sendo a principal referência, e o notebook *Netflix Movies & TV Shows – Linear Regression* (Kaggle), indicado no Projeto 1, agora pode ser aproveitado também na parte de regressão. Para consultas pontuais, vale a documentação do statsmodels e do scikit-learn.

Observação: cuidado para não deixarem de entender o que a IA está fazendo! Lembrem-se de não deixar a IA pensar por vocês durante o desenvolvimento. Ela pode ajudar com dúvidas pontuais de código, mas as decisões do projeto (a pergunta, as variáveis, o modelo e a interpretação dos resultados) precisam ser da dupla, e qualquer uma delas pode ser questionada após a apresentação.